Лабораторная работа №2. Кластеризация

Вариант 3

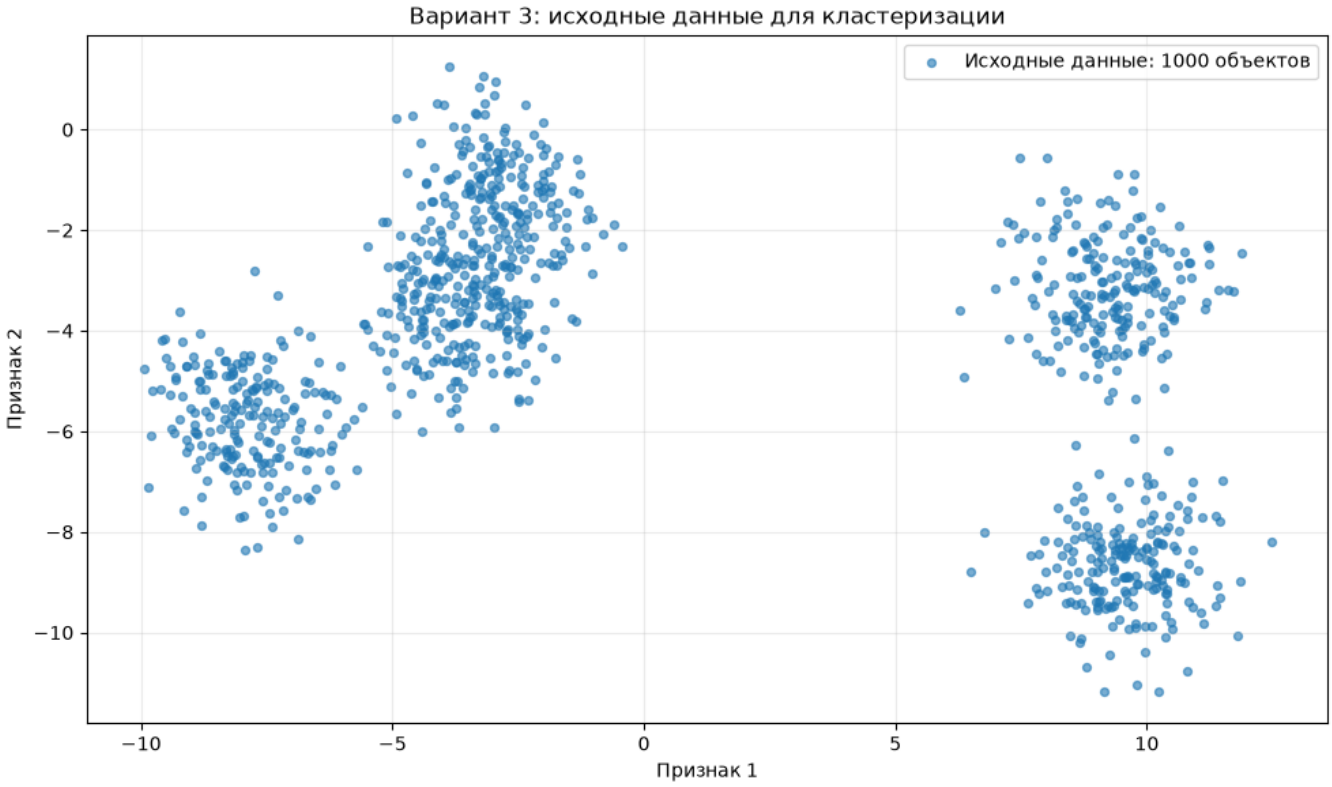
Цель — выделить группы похожих объектов, обосновать число кластеров и обучить модель кластеризации из scikit-learn. На первых двух шагах загрузим данные и посмотрим на их расположение.

1. Загрузка и проверка данных

```
Файл: lab2-03.xlsx
Объектов: 1000, признаков: 2
```

	feature_1	feature_2
0	-4.526108	-3.231157
1	-2.346786	-4.658288
2	-1.722481	-2.705625
3	10.310193	-3.924825
4	-9.949807	-4.761994

2. Визуализация исходных данных



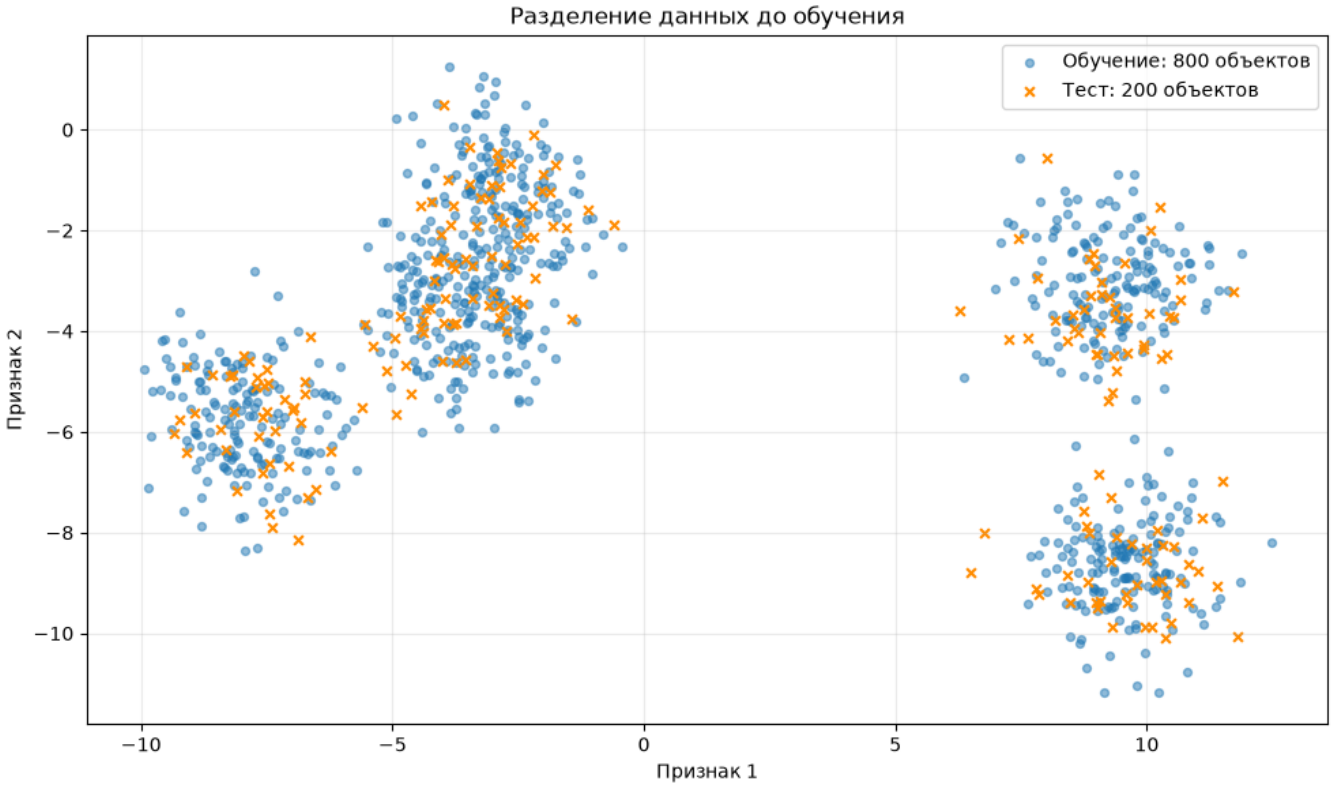
3. Обучающая и тестовая выборки

Случайно выделим 800 объектов для обучения и 200 для последующей проверки.

Фиксируем random_state=42 для воспроизводимости. Тестовые точки не участвуют в подборе центров и числа кластеров.

```
Обучающих объектов: 800
```

```
Тестовых объектов: 200
```



4. Первая модель KMeans

KMeans — метод k средних: k задаёт число групп, а каждая группа представляется центром (средним её координат). Предварительно возьмём k=4 по четырём крупным областям исходного графика. Это гипотеза, которую далее проверим.

Здесь обучаются координаты четырёх центров: по две координаты у каждого.

Как проходит обучение

1. Выбираем начальные центры. Используем k-means++: случайная инициализация с предпочтением точек, удалённых от уже выбранных центров.
2. Относим каждую обучающую точку к ближайшему центру.
3. Перемещаем каждый центр в среднее положение точек своей группы: отдельно усредняем оба признака.
4. Повторяем распределение и пересчёт центров, пока результат не стабилизируется в пределах допуска либо не достигнут предел итераций.

Например, центр группы из точек (2, 4), (4, 6), (6, 5) находится в (4, 5). Этот центр не обязан совпадать с реальным объектом.

Алгоритм уменьшает сумму квадратов расстояний от обучающих точек до центров их групп (inertia). Это похоже на минимизацию квадратов ошибок в регрессии, но здесь измеряем расстояние до центра в двух координатах, а не вертикальное отклонение от линии.

Результат зависит от начальных центров и не гарантирует глобального минимума. `n_init=20` означает 20 запусков с разными начальными центрами; сохраняется лучший по inertia. `random_state=42` делает процедуру воспроизводимой. KMeans сам не выбирает число групп: его мы передаём через `n_clusters`.

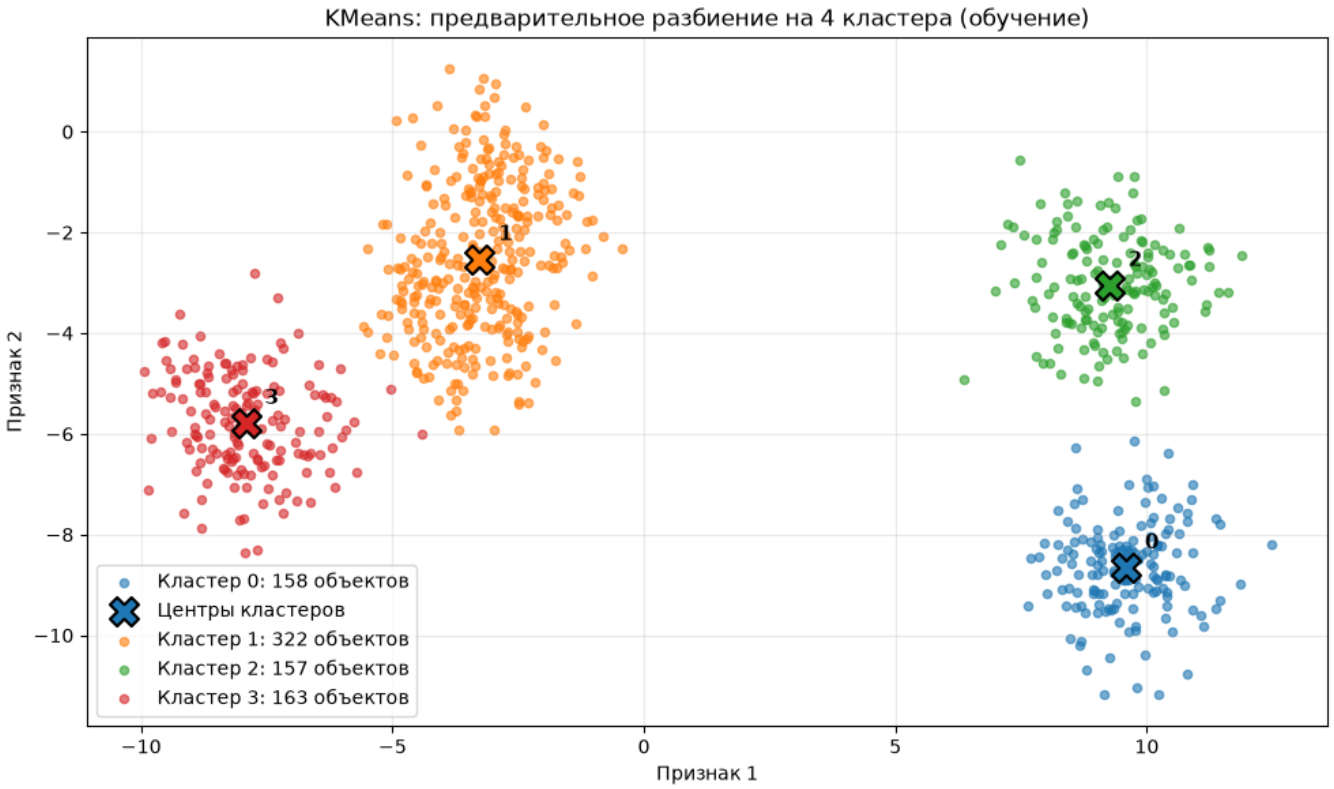
```
Итераций в выбранном запуске: 3
Сумма квадратов расстояний (inertia): 1924.86
Средний квадрат расстояния до центра: 2.41
```

Кластер	feature_1	feature_2	Объектов в обучении
0	9.585	-8.650	158
1	-3.267	-2.525	322
2	9.253	-3.039	157
3	-7.916	-5.779	163

Найденные группы и центры

Покажем только обучающие точки: цвет соответствует присвоенному кластеру, большой крест — его центр. Номера кластеров произвольны, их перестановка не меняет смысл разбиения.

Тестовые объекты пока не распределяем и качество на них не считаем: сначала обоснуем число групп на обучающих данных.

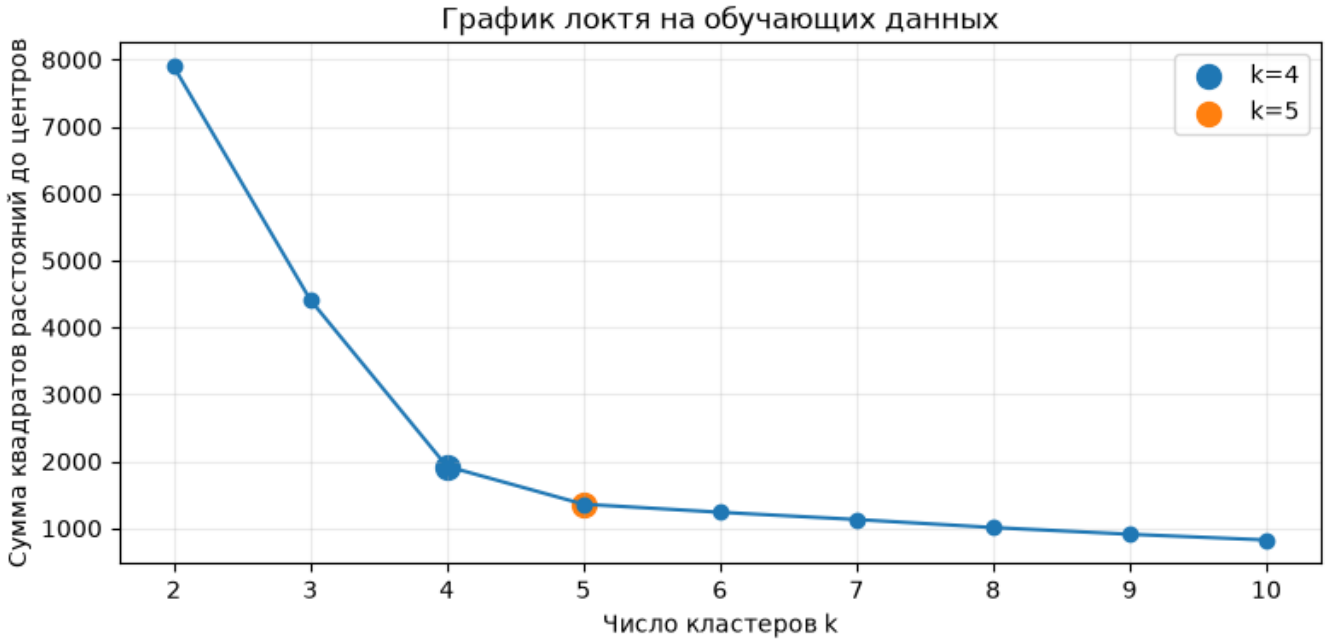


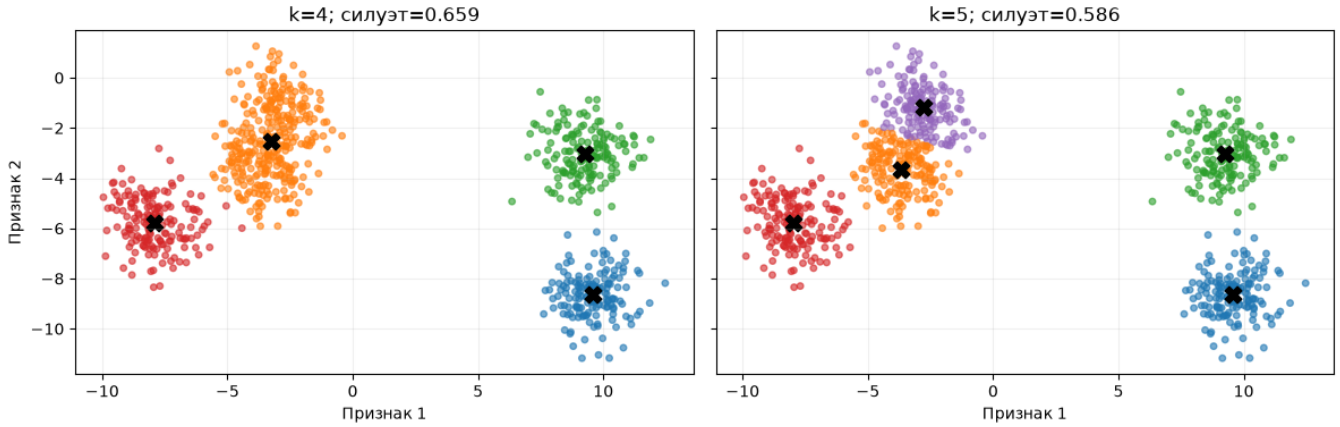
5. Сравнение четырёх и пяти групп

Цель — описать отдельные скопления. Сравним k=4 и k=5 по графику и компактности на обучающих данных. Для контекста построим график «локтя» при k=2…10.

Inertia уменьшается при добавлении центров, поэтому её минимум не определяет число групп. Ищем замедление улучшения. Силуэт оставим дополнительной характеристикой отделённости, без автоматического выбора по максимуму. Масштаб признаков сохраняем исходным.

k	Inertia	Средний квадрат расстояния	Силуэт
2	7898.9158	9.8736	0.7436
3	4413.1857	5.5165	0.6650
4	1924.8628	2.4061	0.6586
5	1359.1573	1.6989	0.5859
6	1238.6024	1.5483	0.5284
7	1129.9423	1.4124	0.4828
8	1010.3160	1.2629	0.4969
9	910.0344	1.1375	0.4184
10	824.6684	1.0308	0.3484





Выбор для подробного описания скоплений

При k=4 вытянутая область слева ближе к центру объединена. При k=5 она разделяется на верхнюю и нижнюю группы, а остальные три скопления сохраняются.

Переход от 4 к 5 уменьшает inertia примерно на 29%, следующий переход от 5 к 6 — только на 9%. Вместе с графиком это даёт основание использовать **k=5 для более подробного описания**. Это обоснованный исследовательский выбор, а не доказательство пяти истинных классов: соседние группы перекрываются, и k=4 остаётся допустимым более крупным разбиением.

Максимум силуэта при k=2 отражает большой промежуток между левой и правой областями. Здесь нас интересуют скопления внутри этих областей, поэтому максимум силуэта не принимаем за обязательное правило.

```
Для дальнейшего анализа выбрано k=5
```

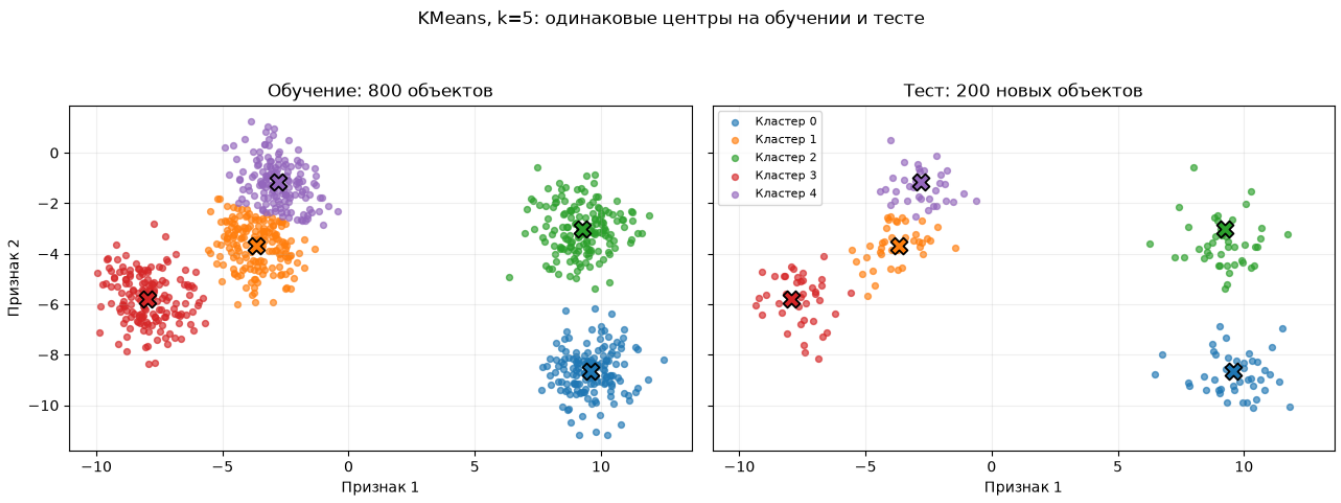
6. Проверка на отложенных объектах

Назначим 200 тестовым точкам ближайшие центры выбранной модели без повторного обучения. Сравним силуэт и средний квадрат расстояния до своего центра; процент правильных ответов неизвестен, поскольку истинных меток нет.

Число групп выбрано по обучающей части. Однако тест уже использовался ранее при исследовании модели с двумя группами, поэтому текущая проверка — исследовательская оценка на отложенной части, а не полностью новый независимый финальный эксперимент. По её результатам k не корректируем.

	Объектов	Представлено кластеров	Средний квадрат расстояния	Силуэт
Обучение	800.0	5.0	1.6989	0.5859
Тест	200.0	5.0	1.7565	0.5731

Кластер	feature_1	feature_2	Объектов в обучении	Объектов в тесте
0	9.585	-8.650	158	42
1	-3.678	-3.681	177	40
2	9.253	-3.039	157	43
3	-7.956	-5.782	161	40
4	-2.791	-1.174	147	35



7. Вывод

KMeans применён к двум числовым признакам в исходном масштабе. Сравнение 4 и 5 групп показало, что пять групп дают более подробное описание вытянутого скопления; уменьшение inertia после пяти замедляется. Разбиение на две области лучше по силуэту, но описывает более крупный уровень структуры.

Принято k=5 как рабочее разбиение для описания отдельных скоплений. Центры найдены по 800 обучающим объектам, остальные 200 распределены по ближайшим центрам. Метрики приведены выше. Предметный смысл признаков и истинные метки неизвестны, поэтому нельзя утверждать, что число групп установлено однозначно.

На тесте средний квадрат расстояния до центра равен 1,7565 (на обучении — 1,6989), силуэт — 0,5731 (на обучении — 0,5859). Показатели близки, все пять групп представлены в тестовой выборке. Это поддерживает применимость разбиения к отложенным объектам, но не доказывает истинность пяти классов.